

Resultados Comparativos dos Experimentos 1, 2 e 3

NCA Optimizer Benchmark

1 Objetivo da análise

Esta seção apresenta os resultados de três protocolos experimentais para comparação de modelos e algoritmos de otimização. O objetivo não é apenas identificar a maior métrica final, mas também avaliar o custo necessário para alcançá-la. Por isso, os resultados são analisados sob três perspectivas:

1. qualidade preditiva no conjunto de teste cego, usando MCC, F1 e acurácia;
2. custo computacional, medido pelo tempo de execução;
3. complexidade empírica do processo de otimização, medida pelo número de treinamentos ou avaliações da função objetivo.

O ponto mais importante da revisão foi separar as métricas. MCC e acurácia não devem ser comparadas diretamente no mesmo eixo, pois medem propriedades diferentes do classificador. Assim, o Experimento 1 é apresentado primeiro pela métrica MCC, enquanto os Experimentos 2 e 3 são apresentados pela acurácia no mesmo conjunto de teste cego.

2 Descrição dos experimentos

Todos os experimentos usam as mesmas sementes principais, os mesmos modelos, os mesmos otimizadores e o mesmo conjunto de teste cego. A diferença entre eles está na função de fitness usada durante a busca e no protocolo de validação.

Tabela 1: Resumo dos três experimentos avaliados.

Experimento	Protocolo		Fitness durante a otimização	Métrica principal reportada
Experimento 1	Holdout 60/20/20	temporal	$0.6 \cdot MCC + 0.4 \cdot F1$	MCC no teste cego
Experimento 2	Holdout 60/20/20	temporal	$0.4 \cdot Acc_{train} + 0.6 \cdot Acc_{val}$	Acurácia no teste cego
Experimento 3	Cross-validation poral	tem-	média dos folds de $0.4 \cdot Acc_{train} + 0.6 \cdot Acc_{val}$	Acurácia no teste cego

O Experimento 3 corresponde ao resultado anteriormente chamado de “Experimento 4”. Na apresentação final, a nomenclatura deve ser corrigida para evitar confusão: os resultados devem ser apresentados como Experimentos 1, 2 e 3.

3 Visão geral dos resultados

A Figura 1 reúne os três experimentos em uma única visualização. A primeira linha mostra o Experimento 1 em MCC. A segunda e a terceira linhas mostram os Experimentos 2 e 3 em acurácia. Essa separação evita comparar valores de natureza diferente.




Figura 1: Visão geral dos Experimentos 1, 2 e 3. O Experimento 1 é reportado em MCC; os Experimentos 2 e 3 são reportados em acurácia.

A leitura principal da figura é que os melhores resultados se concentram no modelo MLP. O MLP aparece como melhor combinação nos três protocolos: MLP+GWO no Experimento 1, MLP+PSO no Experimento 2 e MLP+GWO no Experimento 3. Essa recorrência indica que o ganho não é um caso isolado de uma semente ou de um único otimizador.

4 Experimento 1: Holdout com fitness MCC/F1

O Experimento 1 é o protocolo mais coerente com o problema de classificação financeira, pois otimiza diretamente uma combinação de MCC e F1. O MCC é especialmente importante porque considera simultaneamente verdadeiros positivos, verdadeiros negativos, falsos positivos e falsos negativos. Assim, ele é menos vulnerável a interpretações enganosas quando a acurácia parece boa, mas o classificador erra de forma assimétrica.




Figura 2: Experimento 1 reportado somente em MCC no conjunto de teste cego.

Tabela 2: Melhores combinações por modelo no Experimento 1.

Modelo	Otimizador	MCC	Acurácia	F1	Trein. até 95%	Min. até 95%
MLP	GWO	0.3047	0.6525	0.6601	412	0.83
RF	GA	0.2929	0.6465	0.6694	595	13.62
SVM	GA	0.2898	0.6441	0.6770	780	143.94
CNN	PSO	0.2691	0.6347	0.6517	200	0.66

O melhor resultado absoluto do Experimento 1 foi obtido por MLP+GWO, com MCC médio de 0.3047, acurácia de 0.6525 e F1 de 0.6601. Esse é o maior MCC observado entre as combinações avaliadas e também é a maior acurácia média entre os melhores protocolos. Portanto, quando a prioridade é qualidade preditiva final, o Experimento 1 é o melhor candidato para ser tratado como protocolo principal do artigo.

Um ponto relevante é que MLP+DE ficou muito próximo do melhor resultado, com MCC de 0.3023, mas exigiu apenas 102 treinamentos para atingir 95% do melhor fitness final, contra 412 treinamentos do MLP+GWO. Isso indica que GWO foi o melhor em desempenho absoluto, enquanto DE foi uma alternativa muito forte em custo-benefício.

5 Experimentos 1 e 2 em acurácia no holdout

A Figura 3 mostra a acurácia no teste cego para os dois experimentos com holdout. Essa figura responde diretamente ao pedido de reportar acurácia sem misturá-la com MCC.




Figura 3: Acurácia no teste cego para os Experimentos 1 e 2, ambos com protocolo holdout.

Tabela 3: Comparação dos melhores resultados de holdout.

Experimento	Modelo	Otimizador	Acurácia	MCC	F1	Trein. até 95%	Min. até 95%
Exp. 1	MLP	GWO	0.6525	0.3047	0.6601	412	0.83
Exp. 2	MLP	PSO	0.6523	0.3043	0.6586	114	0.19

Os dois resultados são muito próximos em acurácia. O Experimento 1 ainda apresenta leve vantagem: 0.6525 contra 0.6523. A diferença é pequena, mas o Experimento 1 tem uma vantagem metodológica importante: ele escolhe os hiperparâmetros com base em MCC/F1, métricas mais informativas para problemas em que a acurácia pode esconder erros relevantes. Por isso, mesmo quando olhamos para acurácia, o Experimento 1 continua competitivo.

O Experimento 2, por outro lado, mostra que a otimização direta de acurácia é mais eficiente em termos de avaliações para a melhor combinação MLP+PSO. Ele chegou a 95% do melhor fitness em 114 treinamentos, enquanto MLP+GWO no Experimento 1 precisou de 412. Portanto, o Experimento 2 é forte como análise complementar de eficiência, mas não supera o Experimento 1 como protocolo principal.

6 Experimento 3: Cross-validation com acurácia

O Experimento 3 avalia a versão com validação cruzada temporal e fitness baseado em acurácia. Ele deve ser apresentado separado dos experimentos holdout, pois o protocolo de validação é diferente.




Figura 4: Experimento 3 reportado separadamente: cross-validation temporal com acurácia no teste cego.

Tabela 4: Melhores combinações por modelo no Experimento 3.

Modelo	Otimizador	Acurácia	MCC	F1	Trein. até 95%	Min. até 95%
MLP	GWO	0.6515	0.3028	0.6580	534	1.84
CNN	GA	0.6365	0.2726	0.6537	242	1.41
SVM	DE	0.6103	0.2205	0.6454	15	0.13
RF	GA	0.6081	0.2154	0.6269	37	10.04

O Experimento 3 confirma a robustez do MLP, mas não supera o Experimento 1. A melhor combinação foi MLP+GWO, com acurácia de 0.6515 e MCC de 0.3028. Esses valores são ligeiramente inferiores aos do Experimento 1. Além disso, o custo para atingir 95% do melhor fitness foi maior: 534 treinamentos para MLP+GWO no Experimento 3, contra 412 no Experimento 1.

7 Tempo, custo e complexidade empírica

Para comparar algoritmos de otimização de maneira justa, não basta observar o tempo total, pois pequenas variações de hardware, paralelismo e tipo de modelo podem alterar o tempo de execução. Uma medida mais controlada é contar quantas vezes a função objetivo foi avaliada. Neste projeto, cada linha dos arquivos `*_runs.csv` representa uma avaliação de candidato, isto é, um treinamento ou ajuste de hiperparâmetros.

A complexidade externa dos otimizadores pode ser descrita pelo número de avaliações:

Tabela 5: Interpretação da complexidade externa dos otimizadores.

Otimizador	Forma de contagem	Complexidade externa aproximada
Random Search	número de candidatos amostrados	$O(N \cdot C_{train})$
GA	população $\times$ gerações	$O(P \cdot G \cdot C_{train})$
PSO	partículas $\times$ iterações	$O(P \cdot T \cdot C_{train})$
DE	população $\times$ gerações	$O(P \cdot G \cdot C_{train})$
GWO	lobos $\times$ iterações	$O(W \cdot T \cdot C_{train})$

Como o orçamento máximo foi controlado, o diferencial passa a ser quantas avaliações são necessárias para chegar perto do melhor resultado. A Figura 5 mostra a mediana de treinamentos necessários para atingir 95% do melhor fitness final.




Figura 5: Número mediano de treinamentos necessários para atingir 95% do melhor fitness final em cada experimento.

Tabela 6: Custo mediano por otimizador em cada experimento.

Experimento	Otimizador	Trein. até 95%	Min. até 95%	Runtime total mediano
Exp. 1	DE	126.5	0.66	4.27
Exp. 1	GA	317.0	6.84	22.69
Exp. 1	GWO	261.5	1.18	4.80
Exp. 1	PSO	171.0	3.13	22.68
Exp. 1	RS	560.0	28.51	45.09
Exp. 2	DE	63.0	0.24	4.15
Exp. 2	GA	44.0	0.65	6.95
Exp. 2	GWO	136.3	0.56	4.76
Exp. 2	PSO	50.0	0.27	5.75
Exp. 2	RS	162.0	1.49	4.23
Exp. 3	DE	58.0	0.59	7.68
Exp. 3	GA	139.5	3.20	10.37
Exp. 3	GWO	98.8	1.80	9.89
Exp. 3	PSO	42.0	0.33	10.97
Exp. 3	RS	201.0	4.30	7.98

Essa análise mostra que Random Search foi, em geral, o menos eficiente em número de avaliações. Ele pode encontrar bons candidatos, mas precisa de mais tentativas para se aproximar do melhor resultado. Em contraste, DE, GA e PSO frequentemente chegam mais cedo a uma região de boa solução. No Experimento 1, DE teve o menor custo mediano até 95% do melhor fitness. No Experimento 2, GA teve o menor número de treinamentos. No Experimento 3, PSO foi o mais rápido em número de treinamentos.

8 Síntese dos vencedores

Tabela 7: Resumo dos vencedores por critério.

Critério	Vencedor	Justificativa
Melhor experimento geral	Experimento 1	Maior MCC observado, maior acurácia entre os melhores resultados e fitness mais adequado ao problema.
Melhor modelo	MLP	Aparece como melhor modelo nos três experimentos e mantém baixo tempo de execução.
Melhor otimizador em desempenho final	GWO	Vence no Experimento 1 em MCC e no Experimento 3 em acurácia, ambos com MLP.
Melhor combinação absoluta	Experimento 1 + MLP + GWO	MCC 0.3047, acurácia 0.6525 e F1 0.6601 no teste cego.
Melhor custo-benefício no Experimento 1	MLP + DE	MCC 0.3023, muito próximo do melhor, mas com 102 treinamentos até 95% do fitness.
Melhor alternativa focada em acurácia	Experimento 2 + MLP + PSO	Acurácia 0.6523 e apenas 114 treinamentos até 95% do melhor fitness.

9 Conclusão

O melhor experimento para ser defendido como protocolo principal é o Experimento 1, com holdout temporal e fitness MCC/F1. Ele é o mais consistente metodologicamente porque otimiza métricas mais informativas para classificação financeira e, ao mesmo tempo, entrega o melhor resultado final observado. A melhor combinação absoluta foi MLP+GWO, com MCC de 0.3047, acurácia de 0.6525 e F1 de 0.6601.

O melhor modelo foi o MLP. Ele venceu nos três experimentos quando se considera a melhor combinação por protocolo. Além disso, teve tempo de execução muito inferior ao Random Forest e ao SVM em várias combinações, especialmente quando executado com backend acelerado. Isso torna o MLP a escolha mais forte tanto em desempenho quanto em viabilidade computacional.

O melhor otimizador depende do critério usado. Se o critério principal for desempenho final, GWO é o melhor, pois produziu o melhor resultado absoluto no Experimento 1 e também o melhor resultado do Experimento 3. Se o critério incluir fortemente complexidade empírica, DE e PSO tornam-se alternativas importantes: DE chegou muito perto do melhor MCC no Experimento 1 com menos avaliações, e PSO foi o melhor no Experimento 2 em acurácia.

Portanto, a recomendação final é apresentar o Experimento 1 com MLP+GWO como resultado principal do artigo, acompanhado de uma discussão de eficiência mostrando que MLP+DE e MLP+PSO são alternativas competitivas quando o custo de otimização é priorizado. Essa forma de apresentar os resultados responde à observação do professor: quando os resultados finais são muito parecidos, o diferencial passa a ser quantos treinamentos foram necessários para chegar a bons parâmetros.